

Suivi du profil sociodémographique des étudiants Data d'Openclassrooms

Yannis TALLY



Contexte & indicateurs

- La demande
- Les données
- Les indicateurs choisis
- Les technologies choisis




Méthodologie

Importation des données

DBT :

- Création de sources.yml
- Indiquer nos données brutes
- Faire les tests (source + fraîcheur)



The screenshot shows a code editor interface for a DBT project. At the top, there's a search bar with the text "Search Project 70471823583602 (Workspace)". Below it, there are three tabs: "stg_dem.sql A", "stg_etudiant.sql A", and "sources.yml A X". The "sources.yml A" tab is active. The file path is displayed as "dbt-cloud-70471823559194-etude-socio-dbt > dbt_openclassrooms > models > example > sources > sources.yml". The code content is as follows:

```
DbtPropertiesFile (dbt_yaml_files-latest-fusion.json)
1 version: 2
2 sources:
3   - name: etude_socio
4     schema: public
5     tables:
6       Generate model
7       - name: demographie
8         description: "Les données sont issues des données publiques socio-démographique de L'INSEE"
9       Generate model
10      - name: etudiant
11        description: "Les données proviennent d'un export interne"
```

Importation des données

STAGING :

- Donnée brute
- Config
- Nettoyage de la donnée + RGPD
- Dernière vérification

```
stg_dem.sql A x stg_etudiant.sql A sources.yml A
dbt-cloud-70471823559194-etude-socio-dbt > dbt_openclassrooms > models > example > staging > stg_dem.sql
1  {{config(materialized='view')}}
2  Select
3  *
4  from {{ source('etude_socio', 'demographie')}}
5
6
```

```
stg_dem.sql A stg_etudiant.sql A x sources.yml A
dbt-cloud-70471823559194-etude-socio-dbt > dbt_openclassrooms > models > example > staging > stg_etudiant.sql
1  {{ config(materialized='view') }}
2  SELECT
3  USER_ID,
4  MAX(AGE_GROUP) AS AGE_GROUP,
5  MAX(COALESCE(GENDER, 'inconnu')) AS GENDER,
6  MAX(REGION) AS REGION,
7  MAX(YEAR_PATH_STARTED) AS YEAR_PATH_STARTED
8  FROM {{ source('etude_socio', 'etudiant') }}
9  GROUP BY USER_ID
10
11 |
```

Méthodologie

Importation des données

intermediate :

- Création du dossier intermediate
- Création de from {{ref ()}}
- Création d'une table répondant au besoin métier

```
stg_dem.sql A x stg_etudiant.sql A sources.yml A
dbt-cloud-70471823559194-etude-socio-dbt > dbt_openclassrooms > models > example > staging > stg_dem.sql
1  {{config(materialized='view')}}
2  Select
3  *
4  from {{ source('etude_socio', 'demographie')}}
5
6
```

```
stg_dem.sql A stg_etudiant.sql A sources.yml A
dbt-cloud-70471823559194-etude-socio-dbt > dbt_openclassrooms > models > example > staging > stg_etudiant.sql
1  {{ config(materialized='view') }}
2  SELECT
3  USER_ID,
4  MAX(AGE_GROUP) AS AGE_GROUP,
5  MAX(COALESCE(GENDER, 'inconnu')) AS GENDER,
6  MAX(REGION) AS REGION,
7  MAX(YEAR_PATH_STARTED) AS YEAR_PATH_STARTED
8  FROM {{ source('etude_socio', 'etudiant') }}
9  GROUP BY USER_ID
10
11 |
```

Méthodologie

Importation des données

Les Tests :

- Choix des colonnes
- Mise en place des tests
- Lancement du test
- « dbt test -m stg_etudiant »
- Descriptions

DbtPropertiesFile (dbt_yaml_files-latest-fusion.json)


version: 2

models:


```
- name: stg_etudiant
  description: Modèle de staging contenant les données nettoyées et normalisées des étudiants.
  columns:
    - name: USER_ID
      description: "Identifiant unique d'un etudiant"
      tests:
        - unique
        - not_null
    - name: AGE_GROUP
      description: "Groupe d'âge de l'étudiant."
    - name: GENDER
      description: "Genre possible pour un etudiant"
      tests:
        - accepted_values:
            arguments:
              values: ['F', 'M', 'inconnu']
    - name: REGION
      description: "Région de résidence de l'étudiant."
    - name: YEAR_PATH_STARTED
      description: "Année de début du parcours de l'étudiant."
```

Part des hommes et des femmes par région selon l'INSEE 2026


Part des H/F selon la Région



Part des hommes et des femmes étudiant(e)s par région




Evolution par an du nombre d'étudiant inscrit dans chaque région



Répartition du nombre d'étudiant par région et par an


Nombre d'étudiant par région 2025



REGION

- Île-de-France
- Auvergne-Rhône-Alpes
- Provence-Alpes-Côte d'Azur
- Occitanie
- Hauts-de-France
- Grand Est
- Nouvelle-Aquitaine
- Centre-Val de Loire
- Bretagne
- Pays de la Loire
- Normandie
- Bourgogne-Franche-Comté


Nombre d'étudiant par région 2024



REGION

- Île-de-France
- Auvergne-Rhône-Alpes
- Nouvelle-Aquitaine
- Grand Est
- Occitanie
- Hauts-de-France
- Provence-Alpes-Côte d'Azur
- Bretagne
- Pays de la Loire
- Centre-Val de Loire
- Normandie
- Bourgogne-Franche-Comté


Nombre d'étudiant par région 2023



REGION

- Île-de-France
- Auvergne-Rhône-Alpes
- Hauts-de-France
- Provence-Alpes-Côte d'Azur
- Nouvelle-Aquitaine
- Grand Est
- Occitanie
- Pays de la Loire
- Bretagne
- Normandie
- Centre-Val de Loire
- Bourgogne-Franche-Comté

Nombre d'étudiant par région 2022




REGION

- Île-de-France
- Auvergne-Rhône-Alpes
- Occitanie
- Hauts-de-France
- Nouvelle-Aquitaine
- Grand Est
- Provence-Alpes-Côte d'Azur
- Pays de la Loire
- Bretagne
- Centre-Val de Loire
- Normandie
- Bourgogne-Franche-Comté

Répartition du nombre d'étudiant par âge

Camembert des catégories d'âges



Conclusion

- **Le constat** : Il y'a plus de femmes que d'hommes en France mais beaucoup moins d'étudiantes femmes dans le domaine de la data et beaucoup de reconversions
- **Les recommandations** : Pousser les étudiantes à aller vers se domaine et chercher à rajeunir les l'âge des étudiants – on cherche de jeune femme intéressée par le domaine



Merci

